

Murilo Cesar Osorio

TP1: Algoritmos Genéticos

Trabalho apresentado ao Professor
João Batista Mendes da disciplina
Computação Evolutiva do 6º período
do curso de Engenharia de Sistemas.

1 Introdução

O trabalho consiste na utilização de algoritmos genéticos e seus operadores para resolução de um problema do tipo caixa preta cuja função de saída é dada pela Equação 1. A representação do problema é binária e as soluções candidatas possuem 36 bits, b_1 corresponde ao primeiro, ao passo que b_{36} corresponde ao último bit da *string*.

$$\begin{aligned} y_{saida} = & 9 + b_2b_5 - b_{23}b_{14} + b_{24}b_4 - b_{21}b_{10} + b_{36}b_{15} - b_{11}b_{26} + b_{16}b_{17} \\ & + b_3b_{33} + b_{28}b_{19} + b_{12}b_{34} - b_{31}b_{32} - b_{22}b_{25} + b_{35}b_{27} - b_{29}b_7 \\ & + b_8b_{13} - b_6b_9 + b_{18}b_{20} - b_1b_{30} + b_{23}b_4 + b_{21}b_{15} + b_{26}b_{16} \\ & + b_{31}b_{12} + b_{25}b_{19} + b_7b_8 + b_9b_{18} + b_1b_{33} \end{aligned} \quad (1)$$

É possível perceber, levando a zero os termos que são subtraídos e a um os que são somados, que o valor máximo da Equação 1 é **27**. Portanto, vinte e sete corresponde ao *fitness* ótimo para este problema.

2 Objetivos

Os objetivos deste trabalho são de aprender os conceitos que permeiam o tópico de estudos de Algoritmos Genéticos através da implementação de seus operadores e algumas variantes de cada um deles. Além disso, por ter um estudo estatístico envolvido, o trabalho permite que o aluno possa aprender via gráficos as nuances do dimensionamento de um algoritmo genético, no que diz respeito ao seu comportamento de acordo com a escolha dos operadores, população inicial, taxas de mutação e cruzamento, e diversos outros parâmetros ajustáveis.

3 Materiais e Métodos

O trabalho foi implementado utilizando a linguagem **Python 2.7** com auxílio da bibliotecas **Numpy** e **Matplotlib**. A modelagem foi feita utilizando conceitos de orientação a objetos por tornar mais fácil a compreensão do código e deixar mais claro o encapsulamento dos métodos e atributos.

Foram criadas duas classes; a classe **Pop** modela uma população de tamanho T , dimensão D e uma função de *fitness*, os métodos dessa classe são os operadores de mutação, seleção, cruzamento e substituição; a segunda classe (**GA**) é responsável por processar o dicionário de configurações que o usuário pode informar e realizar os testes. O teste estatístico de Wilcoxon foi calculado utilizando a biblioteca **stats** do pacote **scipy**.

3.1 Classe Pop

Esta classe generaliza uma população com atributos de tamanho (T) e dimensão (D). A população é representada por uma matriz (M) *np.array* com N linhas (indivíduos) e D colunas; o *fitness* é definido pelo usuário como uma função que recebe uma linha dessa matriz e retorna um valor que determina a qualidade da solução.

Os métodos representados por esta classe são:

1. **eval**: recebe a matriz M como entrada e retorna um vetor $F^{1 \times N}$ com os valores de *fitness* de cada solução.
2. **selection**: realiza a operação de seleção na população M , usando o algoritmo de torneio binário ou roleta (a ser definido pelo usuário) e retorna uma nova população S .
3. **crossover**: realiza a operação de cruzamento na população S , usando o algoritmo de cruzamento uniforme ou com um ponto de corte. Retorna uma nova população C .

4. **mutation**: faz mutações na população C com as metodologias bit-a-bit e uniforme. Retorna uma nova população E .
5. **substitution**: faz a substituição da população E na população M inicial utilizando elitismo.

3.2 Classe GA

Esta classe recebe as configurações do algoritmo fornecidas pelo usuário e realiza os testes, também determinados pelo usuário. Seu valor de inicialização é um dicionário com as seguintes chaves:

- **popSize**: <inteiro> tamanho da população;
- **popDim**: <inteiro> dimensão da população;
- **representation**: <str> tipo de representação ['binary'];
- **fitnessEval**: <object> uma função python para calculo de *fitness*;
- **crossRate**: <float> taxa de cruzamento [0,1];
- **crossType**: <str> tipo de cruzamento ['uniform', '1cp'];
- **selectionType**: <str> tipo de seleção ['roulette', 'tournament'];
- **mutationRate**: <float> taxa de mutação [0,1];
- **mutationType**: <str> tipo de mutação ['uniform', '1bit'];
- **maxEpochs**: <int> numero máximo de épocas.

Para realizar os testes, a função **test** implementa um GA geral e recebe como parâmetros a quantidade de testes a serem realizados com as configurações listadas anteriormente e o nome do arquivo que será salvo com os resultados. Cada um dos testes é inicializado com uma população aleatória; ao final do teste, o maior *fitness* da população é inserido num vetor que será retornado ao final de todos os testes.

4 Resultados e Discussões

4.1 Teste 1: Avaliação do efeito do tipo de cruzamento


Os parâmetros para a realização deste teste foram: seleção por roleta, mutação bit a bit, cruzamentos uniforme e com um ponto de corte, taxa de cruzamento igual a 0.8, taxa de mutação igual a 0.025, número de indivíduos igual a 30 e limitada a 50 gerações. Pelos resultados abaixo, podemos perceber que a melhor configuração para o tipo de cruzamento é o uniforme.

Uniforme:

- Número de sucessos: **54**
- Maior *fitness*: **27**
- Menor *fitness*: **25**
- Média dos *fitness*: **26.52**
- Desvio padrão dos *fitness*: **0.61**

Com um ponto de corte:

- Número de sucessos: **0**
- Maior *fitness*: **23**
- Menor *fitness*: **19**
- Média dos *fitness*: **21.12**
- Desvio padrão dos *fitness*: **1**



É visível, pelo *boxplot*, que o primeiro método de cruzamento teve resultado melhor que o segundo. O teste de Wilcoxon resultou em **2.52e-34**, ou seja, os resultados são estatisticamente diferentes.

4.2 Teste 2: Avaliação do efeito do tipo de seleção

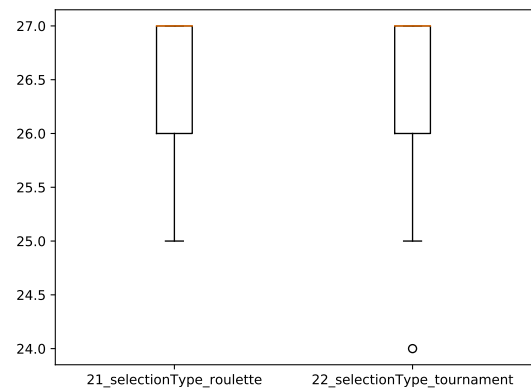
O teste de Wilcoxon para este resultado foi **1.34e-6**, indicando que a diferença entre os resultados foi pequena. De fato, a utilização do método da roleta ou do torneio binário não influenciaram muito no resultado, no entanto, o método da roleta foi ligeiramente melhor nos testes.

Roleta:

- Sucessos: **58**
- Maior *fitness*: **27**
- Menor *fitness*: **25**
- $\mu_{fitness}$: **26.52**
- $\sigma_{fitness}$: **0.61**

Torneio:

- Sucessos: **56**
- Maior *fitness*: **27**
- Menor *fitness*: **24**
- $\mu_{fitness}$: **26.5**
- $\sigma_{fitness}$: **0.63**



4.3 Teste 3: Avaliação do efeito do tipo de mutação

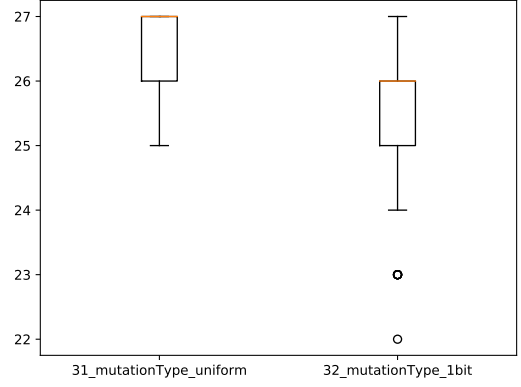
O teste de Wilcoxon para este resultado foi **0.06**, indicando que a diferença entre os resultados foi pequena. De fato, a utilização do método da mutação uniforme ou bit-a-bit não influenciaram muito no resultado, no entanto, o método uniforme foi melhor nos testes no que diz respeito às piores e melhores soluções e na quantidade de sucessos. O *boxplot* mostra os valores fora da curva, chamados *outliers*.

Uniforme:

- Sucessos: **58**
- Maior *fitness*: **27**
- Menor *fitness*: **25**
- $\mu_{fitness}$: **26.52**
- $\sigma_{fitness}$: **0.61**

Bit-a-bit:

- Sucessos: **19**
- Maior *fitness*: **27**
- Menor *fitness*: **22**
- $\mu_{fitness}$: **25.52**
- $\sigma_{fitness}$: **1.14**



4.4 Teste 4: Avaliação do efeito da probabilidade de cruzamento

Os valores para $P_C = 0.8$ já foram mostrados anteriormente. Pode-se perceber que $P_C = 0.8$ retorna os melhores resultados. Os valores do teste de Wilcoxon para as amostras ($P_C = 0.2$, $P_C = 0.5$), ($P_C = 0.2$, $P_C = 0.8$) e ($P_C = 0.5$, $P_C = 0.8$) são, respectivamente, **2.52e-34**, **2.52e-34** e **6.79e-31**; isto indica que os resultados são estatisticamente diferentes.

$P_C = 0.2$

- Sucessos: **0**
- Maior *fitness*: **24**
- Menor *fitness*: **19**
- $\mu_{fitness}$: **20.95**
- $\sigma_{fitness}$: **1.24**

$P_C = 0.5$

- Sucessos: **7**
- Maior *fitness*: **27**
- Menor *fitness*: **23**
- $\mu_{fitness}$: **24.96**
- $\sigma_{fitness}$: **1.09**

